

신뢰 가능한 AI 생태계 조성을 위한 AI 윤리 정책 및 실천 전략

발표자 : 강현비



목 차

I. 개요 및 위기 인식

보고서 목적 · 배경 및 필요성 · 적용 범위

II. AI 윤리 위반 사례 및 시사점

해외 주요 사례 · 국내 주요 사례 · 종합 시사점

III. 국내 AI 윤리 법·제도 현황 및 한계

IV. 현행 가이드라인과 개선안 비교표

V. 주요 정책 제언

단기 · 중기 · 장기 · 공통 과제

VI. 추진 로드맵

VII. 결론 — 지금 결단하지 않으면 늦는다

지금이 골든타임이다

40%+

글로벌 AI 시장 연간 성장률

2,300만

생성형 AI 월간 활성 사용자
전 국민의 45%

6배

딥페이크 피해 증가
3년 새

2만+

개인정보 유출 신고
연간 건수

AI가 의료·사법·채용 등 삶의 핵심 영역에 이미 침투한 상황에서, 윤리 기준 없는 기술 확산은 **차별 자동화**, **개인정보 남용**, **책임 소재 실종**이라는 세 가지 위기를 동시에 현실화한다. EU AI Act 발효(2024.8), 미국 AI 행정명령 시행 — 한국만 뒤처지는 상황이다.

지금 이 순간에도 반복되는 현실

OVERSEAS



미국 COMPAS 재범 예측

"인종 차별의 자동화"

흑인 피고인의 고위험 오분류율이 백인의 2.1배에 달함. 알고리즘 구조 비공개로 이의 제기조차 불가능했습니다.

피부색에 따라 재범 위험 점수가 달라지는 불공정한 양형 결정 사례

OVERSEAS



Amazon 채용 AI 편향

"여성 이력서 자동 탈락"

남성 중심의 10년치 데이터를 학습한 결과, '여대', '여성 클럽' 등 키워드 포함 시 감점 처리되어 운영 중단되었습니다.

과거의 편향된 채용 패턴이 AI를 통해 공식화되어 기회를 박탈한 사례

OVERSEAS



영국 NHS 의료 AI

"인종에 따른 진단 지연"

흑인 환자에게 실제보다 높은 신장 기능을 부여해 진단을 지연시켰습니다. 생명과 직결된 AI 오류가 곧 차별이 되었습니다.

피부색 변수가 알고리즘에 내재화되어 수십년간 검증 없이 방치됨

DOMESTIC



챗봇 '이루다' 사태

"개인정보 무단 활용 및 혐오"

카톡 대화를 동의 없이 수집·학습해 혐오 표현을 생성. 개인정보보호위로부터 1억 원 이상의 과태료 처분을 받았습니다.

내 사적 대화가 허락 없이 AI의 '재료'가 되어 혐오 발언에 쓰인 심각한 사례

DOMESTIC



공공 행정 AI 블랙박스

"왜 탈락했는지 모르는 불투명성"

복지 급여나 주택 선정 탈락 이유를 담당 공무원조차 설명하지 못함. 행정소송에서도 알고리즘 비공개를 이유로 증거 제출을 거부하고 있습니다.

AI 결정에 대해 국민이 이유를 설명받지 못하고 다들 권리조차 없는 행정 불신 초래

종합 시사점: 구조적 피해에 대한 해법



차별의 자동화·확대재생산

데이터의 편향이 AI 판단에 내재화되면, 차별은 기계적으로 반복되고 더 강력하게 고착됩니다.



고위험 영역의 직접 피해

의료, 사법, 채용 등 삶의 기회와 생명에 직결된 영역에서 AI 오류는 회복 불가능한 손실을 줍니다.



민주적 통제 및 권리 구제

투명성 없는 '블랙박스' AI는 시민이 부당한 결과에 이의를 제기할 권리 자체를 완전 차단합니다.



사전 예방 체계가 유일한 해법

이미 발생한 피해는 되돌릴 수 없습니다. 설계 단계부터의 강력한 규제와 검증만이 답입니다.

구속력 없는 가이드라인은 선언에 불과하다

현행 법령 체계

- AI 기본법 (2024.12 제정, 2026.1 시행)
- 개인정보 보호법 개정 (2023): 자동화 결정 거부권 신설
- 국가 AI 위원회 설치 (2024): 대통령 소속

결정적 한계


- 구속력 부재 — 지키지 않아도 제재 없음
- '고위험 AI' 정의 불명확
- 독립 감독기구 부재
- 사전 영향평가 법적 근거 없음

❗ **반론:** '이미 AI 기본법이 있는데 왜 또 규제가 필요한가?' → **대응:** AI 기본법은 2026년 시행 예정이며 핵심 기준이 시행령에 위임된 채 공백 상태다. 법이 있다는 것과 법이 작동한다는 것은 다르다.

8개 항목 중 어느 하나도 실효적으로 작동하지 않는다

구분	현행 (미흡)	개선안 (목표)	기대 효과
법적 구속력	권고 수준, 제재 없음	고위험 AI 법적 의무화 및 제재 명확화	실효적 AI 윤리 규율
고위험 AI 정의	추상적·모호한 기준	EU AI Act 준용 위험등급별 명확 분류	예측 가능한 규율 환경
편향성 검증	권고로만 규정, 실질 검증 없음	출시 전 제3자 감사 의무화	배포 전 차별 위험 차단
설명가능성	일부 권고, 공공 미적용	공공 행정 AI 전면 설명 의무화	국민 권리구제 보장
감독기구	부처 분산, 독립기구 부재	AI 안전청(가칭) 신설	통합·전문 감독 체계
사전 영향평가	법적 근거 없는 자율 시행	고위험 AI 도입 전 법적 의무화	사전 리스크 식별·대응
개인정보 보호	일반 법 준용, AI 특례 미비	AI 학습 데이터 처리 특례 구체화	혁신·프라이버시 균형
국제 협력	개별 MOU 중심 단편 협력	EU AI Act 상호인증·OECD 이행 체계	글로벌 시장 접근성 확보

상호 연계된 정책 패키지 — 어느 하나가 빠지면 실효성이 훼손된다



① **핵심 반론 대응:** 규제가 없는 시장은 신뢰가 없는 시장이다. 스타트업 지원(평가비 70% 지원, 저위험 AI 간소 절차)을 명시 설계. 국내 동일 기준은 '추가 규제'가 아니라 '수출 준비'다.

각 단계는 선택이 아니라 의무다

구분	단기 (2025)	중기 (2026~2027)	장기 (2028~)
법·제도	위험등급 분류 고시 · AI 영향 평가 의무화	AI 기본법 시행령 개정 · 감사 의무화 법제화	AI 피해구제 전담법 제정
조직·인프라	AI 영향평가 전문기관 지정	AI 안전청 출범 · 감사기관 인 증제 도입	피해구제센터 본격 운영
국제 협력	OECD 이행 보고 · EU 상호인 증 협상 개시	EU AI Act 상호인증 협정 체결 · KS 표준화	글로벌 AI 안전 기구 참여 확대

연도별 이행 현황은 국가 AI 위원회에 반기별 보고, 국회 소관 상임위원회에 연 1회 공개.

VII. 결론

지금 결단하지 않으면 늦는다

AI 윤리 정책은 기술 발전을 가로막는 장벽이 아니다. 기술이 국민의 신뢰를 잃지 않도록 지키는 유일한 안전망이다. 신뢰 없는 AI는 결국 사회의 거부에 직면한다.



사전 예방

영향평가와 알고리즘 감사를 통해 잠재적 피해를 배포 이전에 선제적으로 차단해야 합니다.



투명성 법제화

국민이 AI의 결정 과정을 이해하고, 부당한 결과에 대해 구제받을 권리를 명문화해야 합니다.



통합 거버넌스

'AI안전청' 신설로 파편화된 규제를 일관된 체계로 통합하여 행정 효율을 극대화해야 합니다.

즉각적 행동이 필요한 이유

EU의 AI Act와 미국의 행정명령은 이미 시행 중입니다. 우리가 머뭇거리는 사이 우리 기업은 글로벌 표준에서 소외되고, 국민은 안전이 검증되지 않은 기술의 실험 대상이 됩니다.

 2025년 2분기 법무처 협의체 구성 촉구

